Министерство науки и высшего образования Российской Федерации
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ ИТМО
ITMO University

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА
GRADUATION THESIS

Востановление семантических отношений с помощью китайского раздела викисловаря

Обучающийся / Student Хуан Сыюань
Факультет/институт/кластер/ Faculty/Institute/Cluster факультет программной инженерии и компьютерной техники
Группа/Group P34101
Направление подготовки/ Subject area 09.03.04 Программная инженерия
Образовательная программа / Educational program Системное и прикладное программное обеспечение 2019
Язык реализации ОП / Language of the educational program Русский
Статус ОП / Status of educational program
Квалификация/ Degree level Бакалавр
Руководитель ВКР/ Thesis supervisor Клименков Сергей Викторович, Университет ИТМО, факультет программной инженерии и компьютерной техники, старший преподаватель (квалификационная категория "старший преподаватель")
Консультант/ Consultant Письмак Алексей Евгеньевич, ФПИ и КТ, преподаватель (квалификационная категория "преподаватель"), осн., Цопа Евгений Алексеевич, ФПИ и КТ, старший преподаватель (квалификационная категория "старший преподаватель"), осн.

Обучающийся/Student

Документ подписан
Хуан Сыюань
21.05.2023

(эл. подпись/ signature)

Хуан Сыюань
(Фамилия И.О./ name and surname)

Руководитель ВКР/
Thesis supervisor

Документ подписан
Клименков Сергей Викторович
21.05.2023

(эл. подпись/ signature)

Клименков Сергей Викторович
(Фамилия И.О./ name and surname)

Министерство науки и высшего образования Российской Федерации
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ ИТМО
ITMO University

ЗАДАНИЕ НА ВЫПУСКНУЮ КВАЛИФИКАЦИОННУЮ РАБОТУ / OBJECTIVES FOR A GRADUATION THESIS

Обучающийся / Student Хуан Сыюань
Факультет/институт/кластер/ Faculty/Institute/Cluster факультет программной инженерии и компьютерной техники
Группа/Group P34101
Направление подготовки/ Subject area 09.03.04 Программная инженерия
Образовательная программа / Educational program Системное и прикладное программное обеспечение 2019
Язык реализации ОП / Language of the educational program Русский
Статус ОП / Status of educational program
Квалификация/ Degree level Бакалавр
Тема ВКР/ Thesis topic Востановление семантических отношений с помощью китайского раздела викисловаря
Руководитель ВКР/ Thesis supervisor Клименков Сергей Викторович, Университет ИТМО, факультет программной инженерии и компьютерной техники, старший преподаватель (квалификационная категория "старший преподаватель")
Консультант/ Consultant Письмак Алексей Евгеньевич, ФПИ и КТ, преподаватель (квалификационная категория "преподаватель"), осн., Цопа Евгений Алексеевич, ФПИ и КТ, старший преподаватель (квалификационная категория "старший преподаватель"), осн.

Основные вопросы, подлежащие разработке / Key issues to be analyzed
В рамках выпускной квалификационной работы необходимо импортировать в семантическую сеть SemNet информацию о понятиях, их связях с другими понятиями, а так же словоформами для понятий на выбранном подможестве языков.

Цель работы: обеспечение возможности использования семантической сети в задачах обработки текстов на китайском языке
Поставлены следующие задачи: изучить структуру китайской семантики; изучить структуру китайских страниц, а также секций переводов открытого для редактирования словаря Wiktionary; Разобрать страницу Викисловаря и извлечь ее содержимое; разработать методы, которые могут строить новые семантические отношения из существующих семантических отношений; дополнить семантическую сеть новыми связями , полученными за счет реализации алгоритмов на основе разработанного метода; проверить и оценить работоспособность системы на различных частях речи.

В качестве источника данных должны использоваться статьи из открытого для редактирования словаря Wiktionary на нескольких языках, а как хранилище информации должна быть использована существующая семантическая сеть SemNet. Структуру сети необходимо доработать, добавив связи между узлами, содержащими аналогичные понятия

на разных языках.

Язык разработки - Java.

Перечень подлежащих разработке вопросов: анализ существующих решений обработки текста на естественном языке и транслингвальных секций словаря Wiktionary, разработка и реализация алгоритма обработки данных из секций переводов словаря Wiktionary, разработка и реализация метода поиска соответствий между понятиями на исследуемых языках, дополнение семантической сети новыми связями.

Исходные материалы и пособия:
1) Письмак А.Е., Харитонова А.Е., Цопа Е.А., Клименков С.В. Метод автоматического формирования семантической сети из слабоструктурированных источников // Программные продукты и системы - 2016. - № 3. - С. 74-78.
2) С.В.Клименков, В.В.Николаев, А.Е.Харитонова, А.В.Гаврилов, А.Е.Письмак, А.В.Покид. Применение семантической сети для хранения слабоструктурированных данных. Инженерный вестник Дона [электронный журнал]. 2020. № 2. С. 6339. [Тип: Статья, Год: 2020].
3) Покид А. В., Клименков С. В., Цопа Е. А., Жмылёв С. А., Ткешелашвили Н. М. Метод быстрого поиска узлов семантической сети по точному совпадению словоформы // Изв. вузов. Приборостроение. – 2017. – Т. 60, No 10. С. 932-939.
4) Клименков С.В., Цопа Е.А., Николаев В.В., Письмак А.Е., Осика В.П., Яркеев А.С. Method of Reconstruction of Semantic Relations using Translingual Information//Proceedings of the 9th International Joint Conference on Knowledge Discovery, Knowledge Engineering and Knowledge Management (KDIR), 2017, Vol. 2
5) Klimenkov S., Tsopa E., Pismak A., Yarkeev A. Reconstruction of Implied Semantic Relations in Russian Wiktionary//Proceedings of the 8th International Joint Conference on Knowledge Discovery, Knowledge Engineering and Knowledge Management (KDIR), 2016, Vol. 2, pp. 74-80

Форма представления материалов ВКР / Format(s) of thesis materials:
презентация и отчет

Дата выдачи задания / Assignment issued on: 30.01.2023

Срок представления готовой ВКР / Deadline for final edition of the thesis 30.05.2023

Характеристика темы ВКР / Description of thesis subject (topic)

Тема в области фундаментальных исследований / Subject of fundamental research: нет / not
Тема в области прикладных исследований / Subject of applied research: да / yes

СОГЛАСОВАНО / AGREED:

Руководитель ВКР/
Thesis supervisor

Документ подписан
Клименков Сергей Викторович
01.05.2023

Клименков
Сергей
Викторович

(эл. подпись)

Задание принял к исполнению/ Objectives assumed BY

Документ подписан
Хуан Сыюань
01.05.2023

Хуан Сыюань

(эл. подпись)

Руководитель ОП/ Head of educational program

Документ подписан
Дергачев Андрей Михайлович
26.05.2023

Дергачев Андрей Михайлович

(эл. подпись)

Министерство науки и высшего образования Российской Федерации
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ ИТМО
ITMO University

АННОТАЦИЯ
ВЫПУСКНОЙ КВАЛИФИКАЦИОННОЙ РАБОТЫ
SUMMARY OF A GRADUATION THESIS

Обучающийся / Student Хуан Сыюань
Факультет/институт/кластер/ Faculty/Institute/Cluster факультет программной инженерии и компьютерной техники
Группа/Group P34101
Направление подготовки/ Subject area 09.03.04 Программная инженерия
Образовательная программа / Educational program Системное и прикладное программное обеспечение 2019
Язык реализации ОП / Language of the educational program Русский
Статус ОП / Status of educational program
Квалификация/ Degree level Бакалавр
Тема ВКР/ Thesis topic Востановление семантических отношений с помощью китайского раздела викисловаря
Руководитель ВКР/ Thesis supervisor Клименков Сергей Викторович, Университет ИТМО, факультет программной инженерии и компьютерной техники, старший преподаватель (квалификационная категория "старший преподаватель")
Консультант/ Consultant Письмак Алексей Евгеньевич, ФПИ и КТ, преподаватель (квалификационная категория "преподаватель"), осн., Цопа Евгений Алексеевич, ФПИ и КТ, старший преподаватель (квалификационная категория "старший преподаватель"), осн.

ХАРАКТЕРИСТИКА ВЫПУСКНОЙ КВАЛИФИКАЦИОННОЙ РАБОТЫ
DESCRIPTION OF THE GRADUATION THESIS

Цель исследования / Research goal
Обеспечение возможности использования семантической сети в задачах обработки текстов на китайском языке
Задачи, решаемые в ВКР / Research tasks
Проанализировать и обработать страницы Wiktionary для извлечения теста на китайском языке. Создать необходимые объекты в соответствии с семантикой и структурой. Построиться связи между семантиками с помощью установленных правил. Семантическая связь с иностранным языком может быть образована с помощью перевода.
Краткая характеристика полученных результатов / Short summary of results/findings
Работа посвящена обогащению семантической сети SemNet словоформами китайского языка. Пояснительная записка включает в себя: введение с описанием актуальности проводимого исследования. В первой главе производится анализ состояния вопроса, а также применимости викисловаря для китайского языка для семантической сети. Во второй главе производится анализ структуры словаря и способы преобразования его статей в объектую модель, а так же правила создания связей. В третьей главе описывается

архитектура программного решения и разработанные алгоритмы. В четвертой главе приводятся результаты тестирования. . Разработанное программное обеспечение и набор правил позволяют загружать онлайн-страницы китайского Викисловаря и преобразовывать их в классы. Было реконструировано более 5000 семантических объектов. И после анализа примерно 100 000 семантических объектов было установлено более 6000 новых семантических связей. Работа является большим вкладом в разработку семантической сети для китайского языка и обогащении многообразия семантических отношений.

Обучающийся/Student

Документ подписан
Хуан Сыюань
21.05.2023

(эл. подпись/ signature)

Хуан Сыюань

(Фамилия И.О./ name and surname)

Руководитель ВКР/
Thesis supervisor

Документ подписан
Клименков Сергей Викторович
21.05.2023

(эл. подпись/ signature)

Клименков Сергей Викторович

(Фамилия И.О./ name and surname)

ОГЛАВЛЕНИЕ

СПИСОК СОКРАЩЕНИЙ И УСЛОВНЫХ ОБОЗНАЧЕНИЙ 4

ВВЕДЕНИЕ.....5

ГЛАВА 1. АНАЛИЗ ПРЕДМЕТНОЙ ОБЛАСТИ 7

1.1 Причины выбора Викисловаря в качестве источника данных. 7

1.2 Различия между китайским и другими языками и особенности китайского языка 9

1.3 Влияние китайского языка на другие языки 11

1.4 Семантическая сеть 12

1.5 Заключение анализа.....13

ГЛАВА 2. Алгоритмы построения семантических связей 14

2.1 Структура китайского Викисловаря 14

2.2 Построение связей через лексему с единым смыслом 15

2.3 Построение связей через общие синонимы 17

2.4 Построение синонимических связей через общие ссылки 19

ГЛАВА 3. Алгоритмы построения семантических связей 21

3.1 Основная структура проекта.....21

3.2 Использованные технологии 23

3.3 Сегментация и анализ данных 25

3.3.1 Метод сегментации.....26

3.3.2 Разработка парсера 28

3.3.3 Логика и результаты обработки данных 30

ГЛАВА 4. ТЕСТИРОВАНИЕ **32**

4.1 Действительные страницы **32**

4.2 Построение связи **34**

ЗАКЛЮЧЕНИЕ **35**

СПИСОК ЛИТЕРАТУРЫ **37**

СПИСОК СОКРАЩЕНИЙ И УСЛОВНЫХ ОБОЗНАЧЕНИЙ

NLP - Natural Language Processing (Обработка естественного языка)

REST - Representational state transfer (Передача репрезентативного состояния)

API - Application Programming Interface (Программный интерфейс приложения)

ВВЕДЕНИЕ

В современном мире общение через интернет становится все более распространенным и важным способом общения.

Семантическая сеть является важным инструментом для организации и представления знаний. Она помогает связывать концепции и отношения между ними, образуя структуру информации. С помощью семантической сети мы можем легко и эффективно организовывать, хранить и извлекать знания. Она позволяет нам делать выводы, искать аналогии и устанавливать связи между различными понятиями. Семантическая сеть также упрощает обработку естественного языка, понимание контекста и интерпретацию текста. Она может быть использована в различных областях, включая искусственный интеллект, поиск информации, языковые модели и образование. Как результат, семантическая сеть играет важную роль в организации и структурировании знаний для более эффективного и интеллектуального обмена информацией.

Однако различия в языках мешают эффективно обмениваться информацией между культурами, поэтому спрос на правильный и по грамматике, и по смыслу перевод текста постоянно растет.

Викисловарь (Wiktionary) сделал (и продолжает делать) большой вклад в области перевода. Этот проект содержит в себе словари на разных языках, созданные и наполняемые добровольцами.

Однако из-за китайского файрволла и трудностей получить доступ в глобальный интернет, в сети за пределами Китая, мало материалов на китайском языке.

Это приводит к тому, что содержание китайского Викисловаря скудно, и поэтому существует задача улучшить семантические связи между словами китайского и других языков.

В этой работе мы будем проводить исследование по восстановлению этих связей, взяв за основу тексты из Викисловаря. Это позволит нам лучше понять структуру китайского языка для развития языковедения и

искусственного интеллекта, работающего для разных языков.

Для достижения этой цели мы будем обрабатывать и анализировать китайские тексты, используя технологию обработки естественного языка. Мы также будем исследовать, как использовать эти данные для глубокого языкового анализа и построения различных семантических связей, чтобы помочь людям лучше понимать структуру и характеристики китайского языка.

SemNet - семантическая сеть, используемая в выпускной работе, созданная на основе РуТез, Wiktionary и WordNet. Она объединяет тезаурусы и словари, позволяя устанавливать семантические связи. SemNet предоставляет узлы с уникальными идентификаторами, названиями, описаниями и списками словоформ. Узлы классифицируются как sense. Сеть также содержит связи, описывающие отношения между смыслами: гипонимия, гиперонимия, меронимия, холонимия, синонимия и антонимия. Связи реализуются через класс reference с идентификаторами узлов и типами связей. SemNet поддерживает запросы в рамках MVCC-транзакций для беспроблемной работы пользователей. Данные семантической сети хранятся в mmf-файлах, отображаемых в память.

Таким образом, очень важно и актуально установить больше семантических отношений и улучшить семантическую сеть. Нам нужно проанализировать и обработать страницы Wiktionary для извлечения текста на китайском языке, создать необходимые объекты в соответствии с семантикой и структурой и построиться связи между семантиками с помощью установленных правил. Цель данной работы - обеспечение возможности использования семантической сети в задачах обработки текстов на китайском языке.

ГЛАВА 1. АНАЛИЗ ПРЕДМЕТНОЙ ОБЛАСТИ

1.1 Причины выбора Викисловаря в качестве источника данных.

Викисловарь — это онлайн-словарь, управляемый Викимедиа. Он также является самым известным и крупным в мире онлайн-словарем, поддерживающим несколько языков. Его режим работы можно разбить на несколько аспектов:

1.1.1 Создание сообщества: Викисловарь зависит от сообщества энтузиастов, которые вносят, редактируют и корректируют содержание статей. Это сообщество формируется из людей, которые интересуются содержанием словаря. Они могут делиться своими знаниями, а также участвовать в обсуждениях и принимать решения.

1.1.2 Открытое редактирование: Викисловарь использует режим открытого редактирования, то есть любой человек может редактировать статьи в Викисловаре. Это означает, что любой человек может создавать новые статьи, а также изменять, обновлять и дополнять уже существующие статьи. Такой режим открытого редактирования позволяет обновлять и улучшать содержание словаря.

1.1.3 Механизм проверки: Чтобы обеспечить качество и точность содержания Викисловаря, установлены механизмы проверки. Все созданные и измененные статьи проходят проверку со стороны участников сообщества, которые исправляют и дополняют их содержание для обеспечения точности и качества.

1.1.4 Поддержка нескольких языков: Викисловарь поддерживает несколько языков и пользователи могут выбрать тот, с которым им работать комфортнее. В настоящее время Викисловарь поддерживает более 300 языков.

1.1.5 Общественная лицензия: Все материалы Викисловаря публикуются под общественной лицензией, что позволяет людям свободно использовать, изменять и распространять содержание словаря, при условии соблюдения соответствующих условий лицензии.

В целом, формат работы Викисловаря очень открытый и демократичный. Он позволяет участникам сообщества создавать, редактировать и обновлять статьи, что позволяет обеспечивать высокое качество и точность текстов. Многие не носители китайского языка знают и изучают китайский язык с помощью Викисловаря. Поэтому попытка восстановить китайскую семантическую связь в словаре существенно поможет в распространении китайских знаний.

1.2 Различия между китайским и другими языками и особенности китайского языка

Китайский и другие языки имеют много отличий, самым заметным из которых является интонация и способ выражения лексики. Китайский язык является тональным, то есть тон звука может изменять значение слова. В отличие от других языков, в китайском языке изменение тона очень многое значит. Поэтому в китайских иероглифах существуют многозначные слова, то есть одно слово может иметь несколько разных произношений, и каждое произношение имеет разное значение. Давайте рассмотрим очень распространенный пример. Китайский символ «和» имеет пять произношений: «hé», «hè», «huó», «huò», «hú». Первое и второе произношение имеют одинаковое написание в пиньине, но различаются в тонах. Это же относится и к третьему и четвертому произношению. Тем не менее, эти пять значений полностью различны, они соответственно означают «мир», «поддерживать», «добавлять жидкость в порошок и перемешивать или месить», «обманывать» и «выигрывать в игре в маджонг».

А особенность старого китайского заключается в том, что один китайский символ может иметь несколько разных значений, что может затруднить понимание и перевод. В старом китайском языке использование лексики и грамматики отличается от современного. Например, в старом китайском языке глаголы и прилагательные можно использовать взаимозаменяемо.

Благодаря развитию китайской цивилизации и влиянию китайской культуры китайский язык широко распространен в Юго-Восточной Азии, и китайские иероглифы используются в корейском, японском и вьетнамском языках. Однако эти языки сильно отличаются от китайского языка по звучанию, грамматике и лексике, поэтому есть трудности при переводе и понимании.

В целом, китайский язык обладает своей уникальной тональностью,

лексикой и грамматикой, что делает его изучение и понимание вызовом, но также увеличивает его культурное очарование и привлекательность.

1.3 Влияние китайского языка на другие языки

Китайский язык оказывает значительное влияние на другие языки. Исторически, Китай был одной из наиболее развитых цивилизаций в мире, и китайская культура и язык оказали глубокое влияние на культуры и языки соседних и дальних регионов, включая Юго-Восточную Азию, Японию, Корею, Западную и Центральную Азию, а также Европу.

Наиболее заметным примером является использование китайских иероглифов в японском и корейском языках. Китайская лексика широко используется в этих языках, и многие слова в японском и корейском были заимствованы из китайского языка. Кроме того, оба языка используют китайские иероглифы для написания своих слов, хотя произношение их может сильно отличаться от китайского.

Китайский язык также оказал влияние на грамматику и лексику других языков в регионе. Например, многие слова на вьетнамском языке были заимствованы из китайского, а также вьетнамский алфавит был создан на основе китайских иероглифов. Кроме того, китайский язык также оказал влияние на тибетский, монгольский и другие языки.

В целом, китайский язык оказывает значительное влияние на другие языки, в особенности на те, которые используют иероглифы. Вместе с тем, уникальность китайского языка и его культурное наследие продолжают привлекать внимание и интерес со всего мира, в том числе и научных исследователей, студентов и туристов.

1.4 Семантическая сеть

Семантическая сеть - это структурированная система, используемая для представления знаний и отношений между понятиями в виде узлов и связей, с помощью источников информации, таких как: РуТез, Wiktionary и WordNet. РуТез и WordNet являются тезаурусами, а Wiktionary - словарем и тезаурусом. Отличительной особенностью тезауруса от словаря является наличие семантических отношений между терминами. Эти источники данных позволяют задать основу для SemNet и далее заполнять ее, включая ручное добавление значений для развития выбранной предметной области.

В SemNet каждому узлу семантической сети ставится в соответствие уникальный идентификатор и наименование. Узел содержит текстовое описание и список словоформ, принадлежащих ему. Основным классом узлов SemNet является "sense", который описывается уникальным идентификатором, наименованием, текстовым описанием и списком словоформ. Кроме узлов, семантическая сеть характеризуется связями, которые описывают отношения между смыслами в сети. Эти связи могут быть гипонимией, гиперонимией, меронимией, холонимией, синонимией или антонимией.

Связи в SemNet реализуются классом "reference", который содержит поля source_ и destination_, являющиеся идентификаторами связанных узлов, а также поле type_ - тип связи. Кроме того, узлы "sense" могут иметь экземпляры "instance", которые представляют отношение "instance_of", хотя данное отношение не является отдельно описанным в типах "reference". Для выполнения запросов к семантической сети используются MVCC-транзакции, которые не нарушают работу пользователей. Данные семантической сети хранятся в файлах mmf (memory mapped files), отображаемых в память.

1.5 Заключение анализа

Анализ показывает, что китайский Викисловарь открыт и удобен. Структура каждого страницы стандартизирована и понятна. Таким образом, китайский Викисловарь является отличным источником данных для этого проекта и поможет значительно улучшить семантическую сеть словоформами китайского языка.

Однако из-за специфики китайского языка и закрытости Интернета семантическая связь в китайском Викисловаре не идеальна.

Поэтому важно и нужно улучшать китайскую семантическую сеть с помощью китайского Викисловаря. А поскольку китайский язык принадлежит к сино-тибетской языковой семье, он сильно отличается от индоевропейской языковой семьи русского и английского по струтуре. Поэтому многие общие методы и функции не применимы к китайскому языку.

Таким образом, для достижения цели — «Обеспечение возможности использования семантической сети в задаче обработки текстов на китайском языке» необходимо выполнить следующие задачи:

- Проанализировать и обработать страницы Wiktionary для извлечения теста на китайском языке.
- Создать необходимые объекты в соответствии с семантикой и структурой.
- Построить связи между семантиками с помощью установленных правил.

ГЛАВА 2. Алгоритмы построения семантических связей

2.1 Структура китайского Викисловаря

Наиболее распространенные страницы в китайской Вики-словаре основаны на одном символе или слове. Структура такой страницы показана ниже.

Так как китайские иероглифы используются не только в китайском языке, то сначала идет модуль языка. Этот модуль содержит китайские иероглифы и другие модули языка. В этой статье мы будем обсуждать только часть китайского языка. Как описано в разделе 1.2, китайские слова иногда имеют различные произношения, поэтому подмодулем модуля языка обычно является произношение. А каждое различное произношение может включать определение, синонимы, антонимы, происхождение слова, перевод, производные слова и т. д.

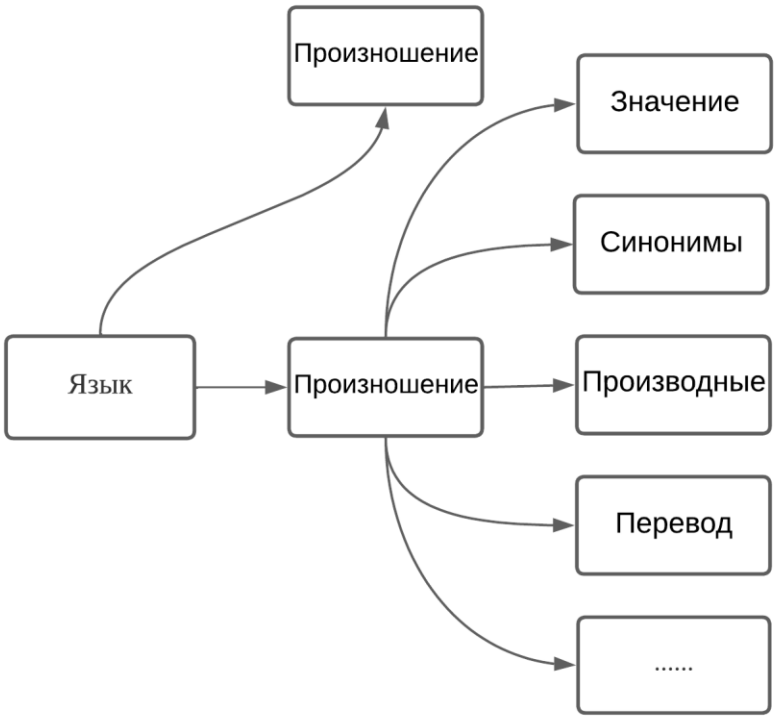

Рисунок 1.Структура китайского Викисловаря

2.2 Построение связей через лексему с единым смыслом

Если лексема содержит только одно смысловое значение (рис. 2), то семантическая связь, указывающая на лексему (L_1S_1 на L_2), может быть заменена ссылкой на этот единый смысл (L_1S_1 на L_2S_1). Из-за неразвитости китайского Викисловаря информация о лексике на многих страницах не идеальна, поэтому обычно они имеют только одно значение. Таким образом, создание этой явной семантической связи очевидно. На этом этапе мы можем создать явную неявную обратную связь между L_2S_1 и L_1S_1.

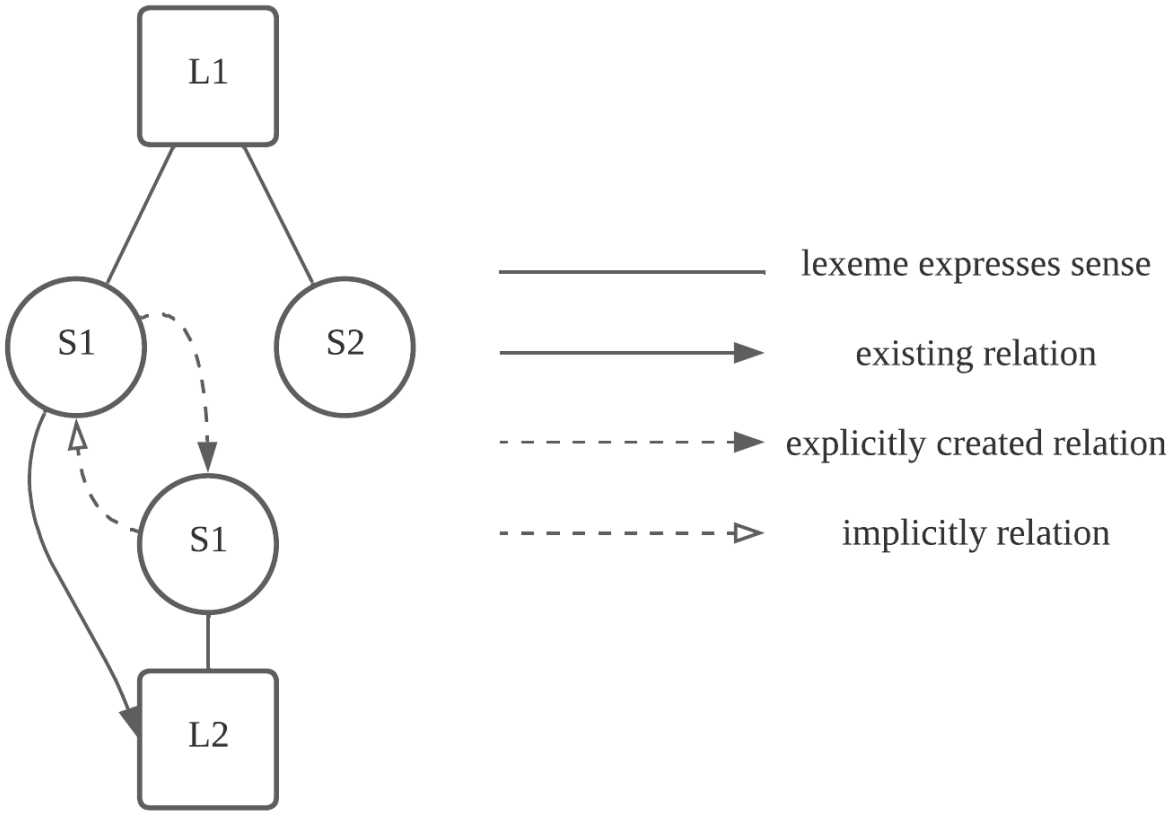

Рисунок 2 лексема с единым смыслом

Например, слово «快樂» (счастливый, L2) содержит однозначное определение «чувство счастья или удовлетворения». А другое слово L1 «滿意

» (довольный) содержит 4 смысла, одно из них - «желания исполняются». Смысл L1S1 имеет отсылку к L2 (счастливый). Поскольку существует только одно определение «счастливый», в нем нет двусмысленности, поэтому L2 (счастливый) является синонимом L1 (довольный). Кроме того, поскольку все семантические связи являются двунаправленными, мы можем создать неявные гиперонимические обратные ссылки между семантикой L2S1 (чувство счастья или удовлетворения) и L1S2 (счастливый).

2.3 Построение связей через общие синонимы

Если смысловые значения связаны как синонимы, мы можем отразить другие существующие связи между смыслами этими синонимами. Точнее, если есть отношение между смыслами, как показано на рисунке ниже, мы можем заключить, что смыслы L_1S_1 и L_3S_1 связаны двунаправленной семантической связью типа R (рис. 3):

1. Смысл L_1S_1 имеет семантическую связь типа R с лексемой L_3.
2. Смыслы L_1S_1 и L_2S_1 являются синонимами друг друга.
3. Лексема L_3 имеет смысл L_3S_1, связанный с L_2S_1 семантическим отношением того же типа R.

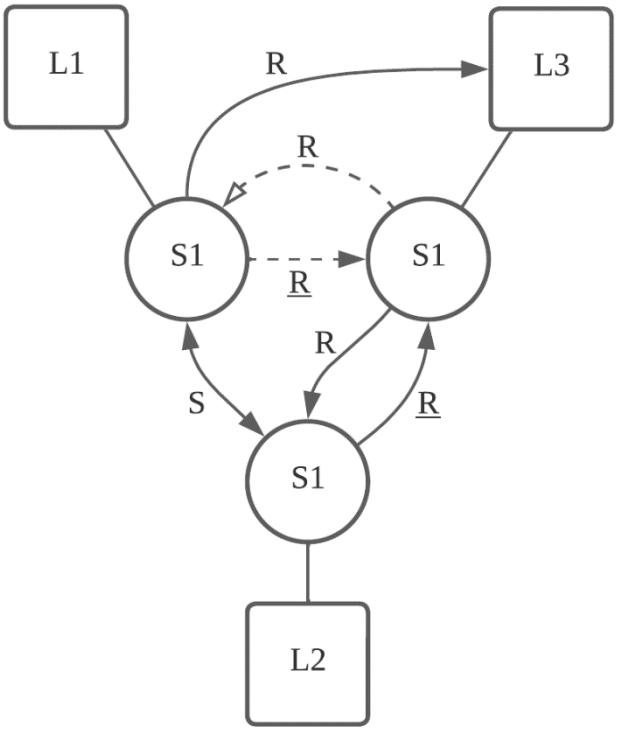

Рисунок 3 Построение связей через общие синонимы

Три лексемы «笋» (бамбуковые побеги, L_1), «植物» (растение, L_3) и «竹» (бамбук, L_2) могут очень хорошо удовлетворить отношение на рис.3. Лексема «笋» (бамбуковые побеги, L_1) содержит смысл «幼年的竹子» (молодой бамбук, L_1S_1), которое содержит гиперонимическую ссылку на лексему L_3 «植物» (растение). Смысл L_1S_1 «幼年的竹子» (молодой бамбук)

также содержит синонимическую ссылку на смысл L_2S_1 «亚竹科» (бамбуковые). Между тем смысл L2S1 (бамбуковые) имеет гиперонимическую отсылку к смыслу «自养的生物» (автотрофные организмы, L_3S_1) лексемы L_3 (растение). Таким образом, мы можем установить связь между L_1S_1 и L_3S_1. Антонимия является симметричным отношением, и мы можем построить имплицитную обратную антонимическую связь от смысла L_3S_1 (автотрофные организмы) к смыслу L_1S_1 (молодой бамбук).

2.4 Построение синонимических связей через общие ссылки

Из предыдущего правила можно вывести аналогичное правило. Когда пара смыслов связана с третьим через одинаковый тип ссылок. Если одна из пар имеет ссылку на лексему второй как синоним, то мы можем создать синонимическую ссылку между этой парой смыслов. Точнее, смыслы и связи между ними должны удовлетворять трем отношениям:

1. Смысл L_1S_1 упоминается как синоним лексемы L_2.
2. Смысл L_1S_1 связан семантической связью типа R со смыслом L_3S_1 лексемы L_3.
3. Любой смысл лексемы L_2 (например, L_2S_1) связан через R-референцию со смыслом L_3S_1.

При выполнении всех этих условий можно сделать вывод, что смыслы L_1S_1 и L_2S_1 являются синонимами (рис.4). В это время мы можем восстановить неявную обратную связь от L_2S_1 к L_1S_1.

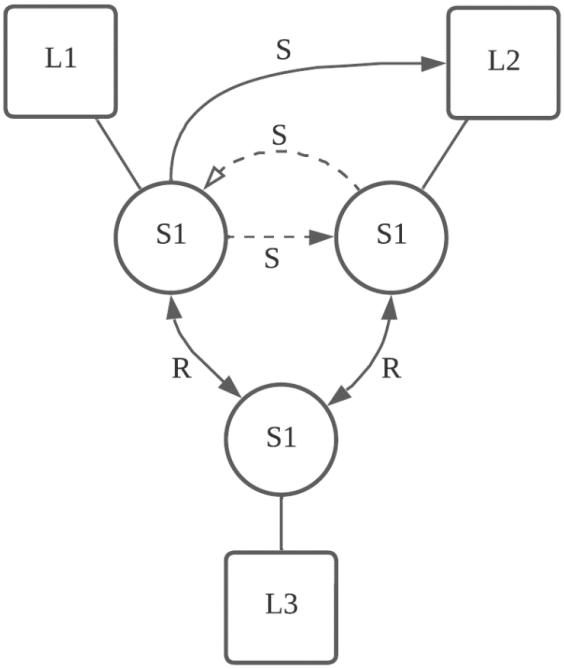

Рисунок 4 Построение синонимических связей через общие ссылки

Три лексемы «潮» (влажный, L_1), «濕»(мокрый, L_2) и «干燥» (сухой, L_3) могут отлично удовлетворить отношение на рис.4. В смысле L_1 содержится синонимическая ссылка на лексему «濕» (мокрый, L_2). Кроме того, смысл L_1S_1 «潮濕，水分多» (сыро, много влаги) содержит антонимическую отсылку к смыслу «指物体含有的水少或不含水»(объект, который содержит мало воды или не содержит ее вовсе, L_3S_1) лексемы «干燥» (сухой, L_3) и смысл «湿润，富含水» (влажный, с большим содержанием воды, L_2S_1) лексемы L_2 также имеют антонимическую ссылку к тому же смыслу.

Таким образом, можно заменить синонимическую связь «смысл-лексема» от смысла L_1S_1 (сырой, с большим содержанием жидкости) к лексеме L_2 (мокрый) на синонимическую связь «смысл-к-смыслу» от смысла L_1S_1 к лексеме L_2 (мокрый). смысл L_2S_1 (влажный, с большим содержанием воды).

ГЛАВА 3. Алгоритмы построения семантических связей

3.1 Основная структура проекта

Разработанный модуль программного обеспечения обрабатывает исходные данные и конвертирует документы для системы семантического анализа. Общая структура проекта выглядит следующим образом:

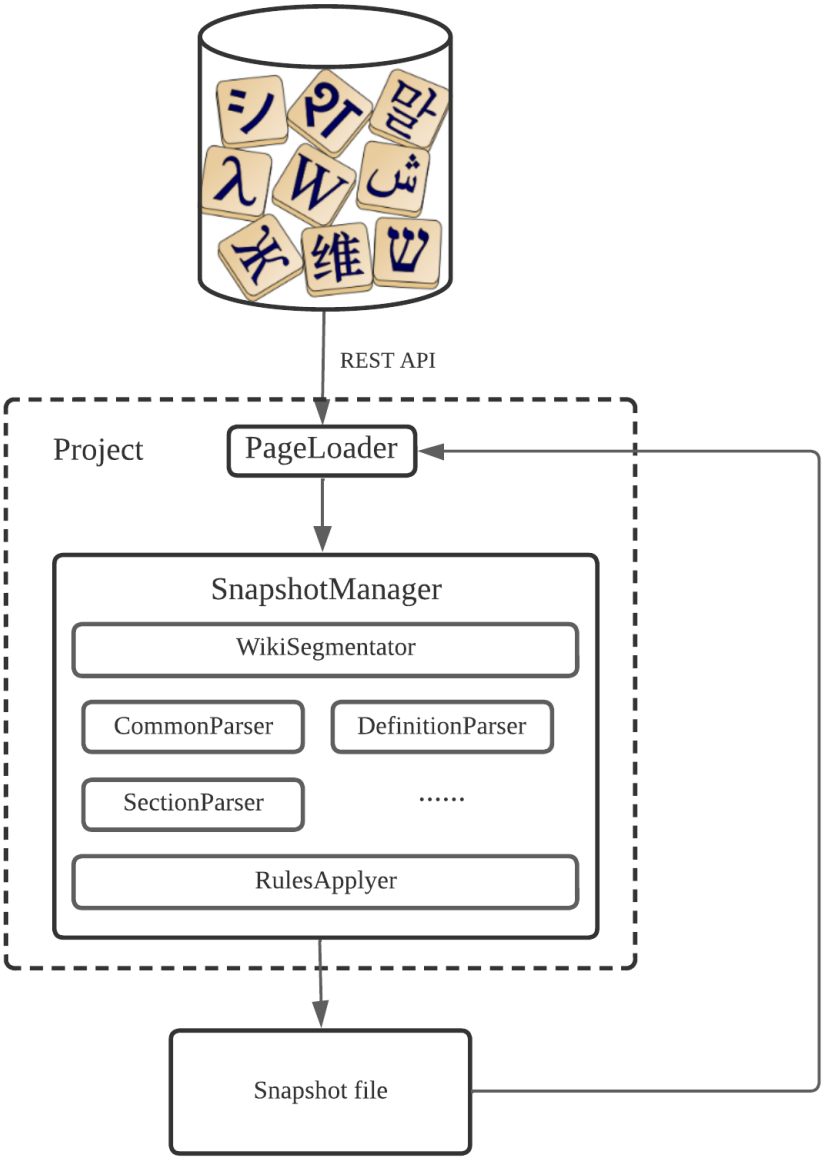

Рисунок 5 Структура проекта

Приложение загружает ресурсы китайских страниц через REST API Викисловаря. Такие шаги, как сегментация, синтаксический анализ и т. д., выполняются с помощью SnapshotManager для преобразования исходных

данных в пригодные для использования объекты WikiSense. Наконец, алгоритм построения связи выполняется через RulesApplyer для получения окончательного результата обработки и создания файла моментального снимка. Мы также можем повторно импортировать обработанные страницы Викисловаря через сгенерированный файл снимка и снова вызвать алгоритм для итеративной обработки.

3.2 Использованные технологии

Проект основан на фреймворке SpringBoot и управляет зависимостями и версиями через Maven, а за фронтенд-взаимодействие отвечают скрипты Groovy. (Разработка в операционной системе Ubuntu.)

Пользователи подключаются к серверной части с помощью команд telnet и используют команды Groovy для вызова методов в компонентах.

Серверная часть автоматически собирает связанные компоненты через SpringBoot, позволяя контейнеру управлять объектами. И используется аннотация @GroovyAccessible, чтобы обеспечить возможность взаимодействия со сценариями Groovy. Поскольку существует две версии китайского языка: традиционный и упрощенный китайский, и некоторые шрифты в них разные, но с одним смыслом, то в этом проекте используется библиотека Opencc4j для конвертации традиционного и упрощенного вариантов.

В данном проекте реализованы следующие функции:

- Менеджер моментальных снимков

Эта функция используется для взаимодействия с Groovy script, управления снимками и работы с целевыми снимками.

- Фильтрация целевого языка

Эта функция удаляет вики-страницы на нецелевых языках из снимков.

- Сегментация страниц китайского Викисловаря

Используется для разделения исходной вики-страницы на части и преобразования ее в нужный объект.

- Анализ страниц китайского Викисловаря

Эта функция используется для разбора объектов вики-страницы в

семантические объекты, которые содержат парсеры для разных модулей.

- Анализ определения

Эта функция может извлекать ключевую информацию из исходной информации определения объекта вики-страницы и исключать недопустимое содержимое.

- Анализ общий контент

Эта функция служит функцией анализа по умолчанию и может анализировать исходные данные в распространенных форматах.

- Анализ перевода

Эта функция анализирует переводы из Викисловаря, группируя переводы в соответствии с разными определениями слов, причем каждая группа содержит разные языки.

- Извлечение связей

Эта функция может извлечь желаемую семантическую связь из проанализированных данных.

- Создание вики-раздела

Эта функция преобразует все проанализированные данные в объекты, которые могут быть непосредственно использованы правилами.

- Применения правил

Эта функция состоит из вызова четырех семантических правил и объединения выходных результатов.

3.3 Сегментация и анализ данных

Контент Викисловаря имеет определенный формат, и мы находим правила, просматривая большое количество страниц и разрабатывая сегментаторы и парсеры.

Пример необработанных данных показан ниже (перевод на русский есть справа):

```
==漢語==                                    // Китайский язык
{{zh-forms|s=快乐}}

===發音===                                  // Произношение
{{zh-pron
|m=kuàilè,tl=y
|c=faai3 lok6}}

====釋義====                                // Значение
* 指作爲人的一種心態；感到高興或滿意。

====近義詞====                              // Синонимы
{{zh-syn-saurus|喜悅}}

====衍生詞====                              // Производные
{{zh-der|快樂丸|快樂原則|快樂主義|春節快樂}}

====翻译====                                // Перевод
英語：{{t+|en|happy}}、{{t+|en|joyful}}
====參見====                                // Цитата
* {{zh-l|開心}}
* {{zh-l|幸福}}
```

Рисунок 6 Исходные данные и аннотации

3.3.1 Метод сегментации

漢語

發音

- 官話 [更多 ▼]
  (拼音): kuàilè
  (注音): ㄎㄨㄞˋ ㄌㄜˋ
- 粵語 (粵拼): faai^3 lok^6

正體/繁體 (快樂)	快 樂
簡體 (快乐)	快 乐

釋義

- 指作爲人的一種心態；感到高興或滿意。

近義詞

快樂 的同義詞 [显示▼] edit

衍生詞

- 快樂丸 / 快乐丸 (*kuàilèwán*)
- 快樂主義 / 快乐主义
- 快樂原則 / 快乐原则
- 春節快樂 / 春节快乐
- 生日快樂 / 生日快乐 (*shēngrì kuàilè*)

翻译

- 英語: happy (en)、joyful (en)

参見

- 開心 / 开心
- 幸福 (*xìngfú*)

Рисунок 7 Страница Викисловаря для рис.6

Наблюдая за страницей Викисловаря (рис. 7) и примером необработанных данных (рис. 8), мы видим, что количество знаков равенства связано с уровнем страницы. В качестве корневого каталога используется «中文» (китайский) с 4 знаками равенства. Этот модуль содержит модули «發音» (произношения) со 6 знаком, а модуль произношения содержит модули с 8 знаком, таких как «釋義» (определение), «近義詞» (синонимы) и «衍生詞»(производные).

Мы выполняем построчное чтение исходных данных. Создаваем новый объект WikiSection, когда мы читаем строку, начинающуюся с "=". Если количество "=" больше, чем количество знаков равенства в предыдущей строке, объект будет добавлен как вложенный объект предыдущего WikiSection. Если равны - добавится параллельно. Если меньше, то объект

добавляется извне.

Блок-схема метода сегментации выглядит следующим образом:

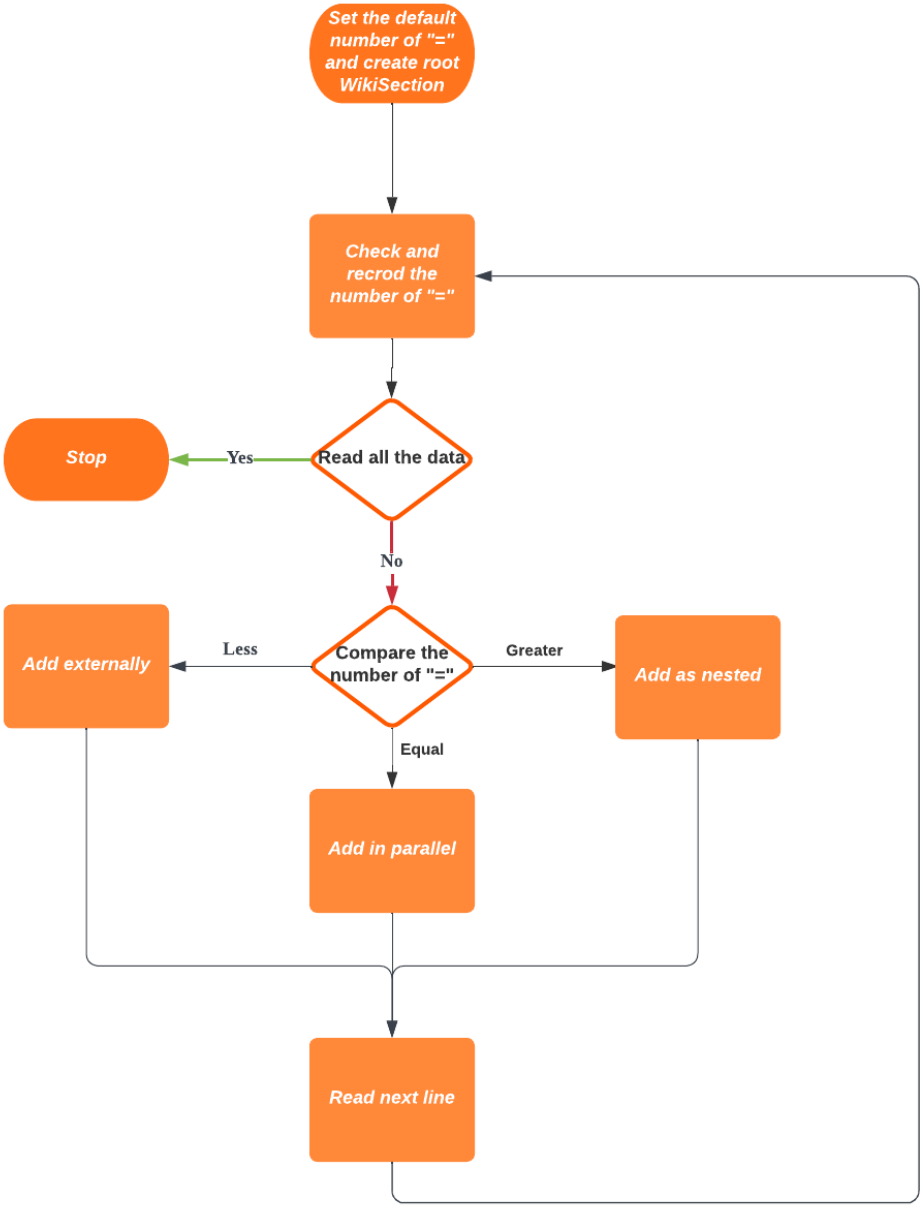

Рисунок 8 Блок-схема метода сегментации

3.3.2 Разработка парсера

Необработанные данные проходят через сегментатор для формирования объектов WikiSection, и каждый объект содержит только необработанные данные этой части. Поэтому нам нужно установить соответствующие парсеры для разных частей. SnapshotManager может назначить соответствующий анализатор объекту, прочитав поле SenseOption в WikiSection. Обычный парсер назначается, если нет соответствующего парсера.

Поскольку исходные данные разных частей имеют свой специфический формат, мы обычно получаем содержимое через регулярные выражения. Только переведенные части вики-страниц показаны и проанализированы ниже в качестве примеров:

```
// Type 1
====翻译====
* 英語：{{t+|en|happy}}、{{t+|en|joyful}}、{{t+|en|cheerful}}
* 俄语：{{t+|ru|ра́достный}}、{{t+|ru|весёлый}}
* 乌克兰语：{{t|uk|ра́дісний}}、{{t|uk|весе́лий}}
```

Название на китайском языке
Тег перевода
Аббревиатура типа языка
Перевод

Рисунок 9 Структура раздела перевода

Наблюдая за структурой части перевода, мы можем знать, что перевод каждого языка представляет собой строку, а строка открывается знаком «*». Далее следует тип языка перевода, а после ":" - часть перевода (здесь двоеточие в китайском языке отличается от английского). Объект перевода состоит из тега перевода, аббревиатуры типа языка и текста перевода. Поскольку иногда аббревиатура типа языка отсутствует, а существует только тип китайского языка, я создал в программе карту в виде сравнительной таблицы аббревиатур. Мы получаем часть перевода с помощью регулярных выражений и делим каждый

объект в соответствии с «|», и, наконец, получаем текст перевода. Реализованный код выглядит следующим образом:

```
private String parseLang(String line) {
    String result = null;
    Matcher mForLangHead = Pattern.compile("\\*(.*?)[:: ]").matcher(line);
    Matcher mForLangInContent = Pattern.compile("\\{\\{t[+]?(.*?)}}").matcher(line);

    if (mForLangHead.find()) {
        result = getLangFromZhLangMap(mForLangHead.group(1)
            .replaceAll("\\*", "")
            .replaceAll("[:: ]", "")
            .trim());
    }

    if (result == null && mForLangInContent.find()) {
        String[] tmp = mForLangInContent.group(1).split("\\|");
        if (tmp.length > 1) {
            result = tmp[1];
        }
    }
    mForLangHead = Pattern.compile("\\*(.*?)[:: ]").matcher(line);
    if (result == null && mForLangHead.find()) {
        return mForLangHead.group(1)
                .replaceAll("\\*", "")
                .replaceAll("[:: ]", "")
                .trim();
    }

    return result
}
```

Рисунок 10 Код ключа парсера перевода

3.3.3 Логика и результаты обработки данных

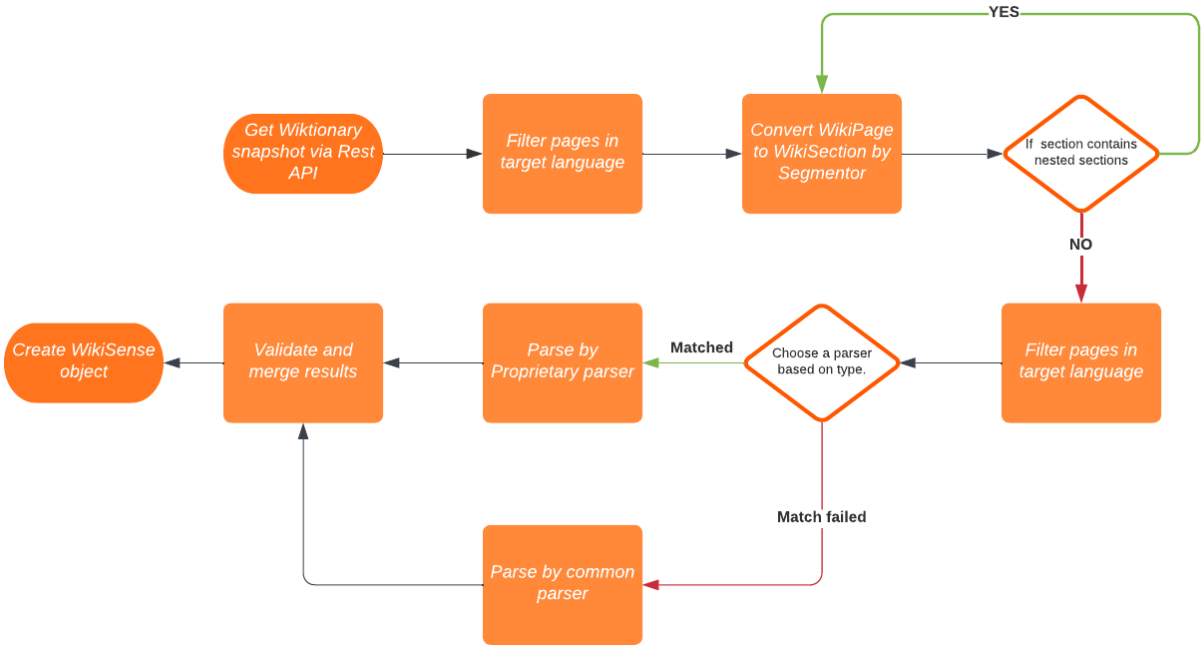

Рисунок 11 Блок-схема обработки данных

Сначала мы получаем данные через REST API из Викисловаря, затем отфильтровываем страницы на нужном языке.

Затем разделяем вики-страницу на разделы и преобразуем их в WikiSection objects. Если раздел содержит другие разделы, то повторяем прошлый шаг. Иначе фильтруем и получаем китайский раздел.

Затем мы попытаемся найти́ специальный парсер для каждой секции и распарсить её им. Если специального нет, то используем парсер общего назначения. Наконец, мы проверяем и объединяем результаты отдельных синтаксических анализаторов и используем их для создания необходимого объекта WikiSense.

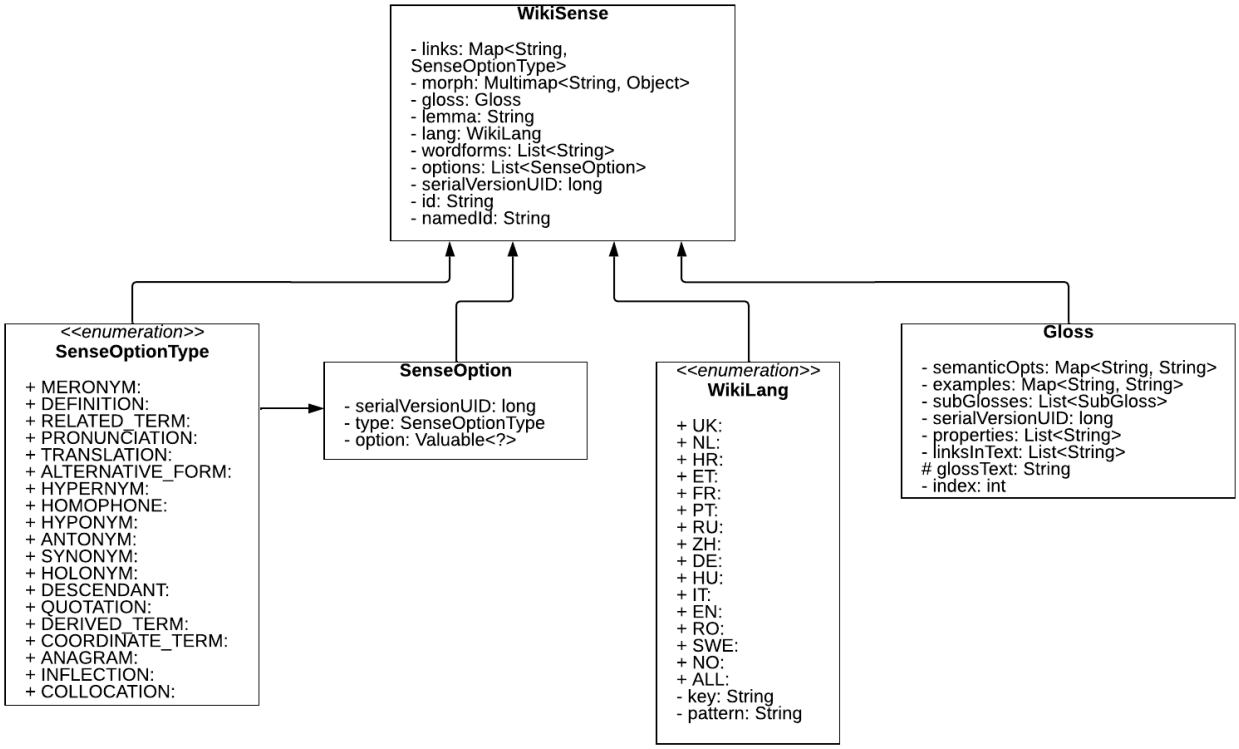

Рисунок 12 Структурная WikiSense

Структура WikiSense, которую мы получаем после обработки, показана сверху. Она содержит язык, лемму, модули, которые можно анализировать на странице, такие как определения, синонимы, антонимы и т. д. Ссылки и параметры опций содержат связи, полученные с этой страницы, и мы будем использовать их для создания новых семантических связей.

ГЛАВА 4. ТЕСТИРОВАНИЕ

4.1 Действительные страницы

Чтобы получить достаточное количество страниц китайского Викисловаря, я случайным образом скачал 1 000 000 страниц через скрипты на Groovy, что заняло около двух часов.

После проверки оказалось, что только 90 000 страниц содержат китайские модули, что составляет всего 9%. Это связано с тем, что Китайский Викисловарь содержит не только страницы китайской лексики, но и слова для всех языков. Но некитайские слова не включены в цель исследования этого диплома, поэтому они не рассматриваются.

Этот проект также может загружать страницы Викисловаря на других языках. Я пробовал загружать страницы на разных языках, и результаты следующие:

Таблица 1 Действительные страницы на нескольких языках

Язык / Кол-во скач. стр-ц.	Китайский	Русский	Английский	Немецкий
1.00E+03	92	383	221	157
1.00E+04	2532	4320	4211	3762
1.00E+05	8920	25042	19530	12421
1.00E+06	95042	290577	215822	114352

Сравнивая количество подходящих для исследования страниц среди

скаченных на китайском, русском, английском и немецком языках, можно увидеть, что среди них русских и английских текстов Викисловаря больше всего. Их доля составляет около 29% и 23.5% соответственно.

Китайский раздел не идеален и мал по размеру. Вероятно, это из-за сложности добавления нового текста из-за изолированности интернета Китая. Я попросил своих друзей в материковом Китае попытаться получить доступ к Викисловарю, но никто из них не смог получить к нему доступ. Викисловарь основан на страницах, отредактированных пользователями. Материковый Китай является регионом с наибольшим количеством носителей китайского языка, и неспособность людей получить доступ к Викисловарю напрямую приводит к отсталости китайской Вики.

4.2 Построение связи

Как упоминалось в предыдущем разделе, я получил 95042 действительных страницы китайских слов, загрузив 1 000 000 случайных страниц китайского Викисловаря. После синтаксического анализа была извлечена семантика 21381 и установлены соответствующие объекты WikiSense.

Для всего объекта снапшота было выполнено три правила, и весь процесс занял около 10 минут. Первое правило установило 18322 связи, второе правило установило 3781 связь, а третье правило установило 2709 связей. Наконец, результаты трех правил были объединены для создания файла моментального снимка размером около 50 МБ.

Затем мы читаем сгенерированный снимок и импортируем его в приложение. (Процесс занимает всего 10 секунд) И выполняем три правила на этом снимке, итерируя. Так как при первом исполнении первое правило устанавливает связи для однозначных морфем, то во второй итерации первое правило уже не устанавливает никаких связей. Второе правило установило 301 связь, а третье правило установило 66 связей.

Наконец, мы делаем вторую итерацию, которая занимает всего 2 секунды, но три правила в сумме создают только однозначные связи. Поэтому мы не делаем третью итерацию.

После двух итераций первое правило установило в общей сложности 18322 связи, второе правило установило в общей сложности 4082 связи, а третье правило установило в общей сложности 2775 связей. Всего алгоритм установил 25179 связей из 21381 семантики.

ЗАКЛЮЧЕНИЕ

Работа была направлена на восстановление семантических отношений через китайскую часть Википедии, а также на предоставление ссылок и поддержки для построения графов обработки и знаний китайского естественного языка. Сначала были случайным образом загружены 1 000 000 страниц через программу Groovy, и после проверки только более 90 000 страниц содержали китайские модули. Затем мы использовали эти страницы для построения объектов WikiSense, которые заложили основу для последующего установления семантических связей.

В работе были использованы три правила для установления семантических связей. В первой итерации мы успешно установили 18322 связи, во второй итерации мы успешно установили 4082 связи, в третьей итерации мы успешно установили еще 2775 связей. Всего мы установили 25179 связей из 21381 семантики. Хотя количество ссылок, установленных в этой статье, все еще относительно невелико по сравнению с общим количеством страниц в китайском разделе Википедии, семантические отношения, охватываемые этими связями, относительно полны и богаты. Для дальнейших исследований можно рассмотреть возможность загрузки и фильтрации большего количества страниц Википедии, чтобы построить более полную сеть семантических связей. Или напрямую заменить источник данных, используя «Baidu Baike» (собственная китайская Википедия) в качестве источника данных, и тогда, возможно, доступность страниц будет больше. Недостаток в том, что нет интернационализации Викисловаря, а некоторые данные могут быть не в открытом доступе.

Однако алгоритм в этой статье нуждается в дальнейшем совершенствовании. Мы можем рассмотреть возможность введения более сложных правил для повышения точности и охвата связей. Например, отношения синонимов устанавливаются через один и тот же перевод, а отношения антонимов устанавливаются через антоним синонима.

В работе были выполнены следующие задачи:

- Проведен анализ и обработаны страницы Wiktionary для извлечения теста на китайском языке. Успешно загружено 1 000 000 случайных страниц Викисловаря, проанализировано и обработано более 90 000 страниц китайского Викисловаря.

- Были созданы необходимые объекты WikiSense в соответствии с семантикой и структурой. Успешно разобрано, проанализировано почти 90 000 страниц Викисловаря на китайском языке и созданы соответствующие объекты WikiSense.

- Построены связи между смысловыми единицами с помощью установленных правил. Были успешно применены три правила, которые установили 18 322, 4 082 и 2 775 связь соответственно, всего 25 179 связи.

Все три задачи были полностью выполнены. Связи, установленные проектом, очень помогли обогатить семантическую сеть словоформами китайского языка. Таким образом, цель выпускной квалификационной работы "Обеспечение использования возможностей семантической сети в возможности обработки текстов на китайском языке" была достигнута.

СПИСОК ЛИТЕРАТУРЫ

1. Клименков С.В., Цопа Е.А., Письмак А.Е., Yarkeev A. Reconstruction of Implied Semantic Relations in Russian Wiktionary//Proceedings of the 8th International Joint Conference on Knowledge Discovery, Knowledge Engineering and Knowledge Management (KDIR), 2016, Vol. 2, pp. 74-80
2. Клименков С.В., Цопа Е.А., Николаев В.В., Письмак А.Е., Осика В.П., Яркеев А.С. Method of Reconstruction of Semantic Relations using Translingual Information//Proceedings of the 9th International Joint Conference on Knowledge Discovery, Knowledge Engineering and Knowledge Management (KDIR), 2017, Vol. 2
3. Письмак А.Е., Харитонова А.Е., Цопа Е.А., Клименков С.В. Метод автоматического формирования семантической сети из слабоструктурированных источников // Программные продукты и системы - 2016. - № 3. - С. 74-78.
4. С.В.Клименков, В.В.Николаев, А.Е.Харитонова, А.В.Гаврилов, А.Е.Письмак, А.В.Покид. Применение семантической сети для хранения слабоструктурированных данных. Инженерный вестник Дона [электронный журнал]. 2020. № 2. С. 6339. [Тип: Статья, Год: 2020].
5. Sunfyre, MatSuBot, Xiaoman, Artoria2e5. WIKIDATA, Bambusoideae. Режим доступа: https://www.wikidata.org/wiki/Q670887
6. Sayonzei, Cewbot, OctraBot, Wjcdbot. Wiktionary, 快樂 (счастливый). Режим доступа: https://zh.wiktionary.org/wiki/%E5%BF%AB%E6%A8%82
7. Alexbot, Interwicket, Lccfbot. Wiktionary, 潮(влажный). Режим доступа: https://zh.wiktionary.org/wiki/%E6%BD%AE
8. Alexbot, Interwicket, Lccfbot. Wiktionary, 濕(мокрый). Режим доступа: https://zh.wiktionary.org/wiki/%E6%BF%95

9. Wjcdbot, Interwicket, VolkovBot. Wiktionary, 干燥(сухой). Режим доступа: https://zh.wiktionary.org/wiki/%E5%B9%B2%E7%87%A5
10. Seasurfer, RobotGMwikt, Interwicket, Wjcd. Wiktionary, 满意(довольный). Режим доступа: https://zh.wiktionary.org/wiki/%E5%B9%B2%E7%87%A5
11. Alexbot, TongcyBot, OctraBot. Wiktionary, 笋 (бамбуковые побеги). Режим доступа: https://zh.wiktionary.org/wiki/%E7%AC%8B
12. Sayonzei, Xiaowei, Jusjih. Wiktionary, 植物(растение). Режим доступа: https://zh.wiktionary.org/wiki/%E6%A4%8D%E7%89%A9
13. Jinguyonglong, Wihwang, Interwicket. Wiktionary, 竹 (бамбук). Режим доступа: https://zh.wiktionary.org/wiki/%E7%AB%B9